COLEGIO ARRIARÁN BARROS

Pensamiento Computacional y Programación · 3° y 4° Medio

Guía de autoaprendizaje: trabajar con DataFrames

Contexto: la cafetería del colegio (se trabaja en Google Colab)

Nombre:	**Curso:**	**Fecha:**

Cómo usar esta guía

- Avanza a tu ritmo, de la Parte 1 a la Parte 6. Cada parte tiene una idea, un ejemplo con su resultado y una actividad "Prueba tú".
- Escribe cada ejemplo en una celda de Colab y ejecútalo. **Compara lo que ves con el resultado de la guía**: si es distinto, revisa tu código antes de seguir.
- Al final de la guía hay una sección con las respuestas para que compruebes tu trabajo. Intenta primero sin mirar.
- En Colab verás las tablas con formato; en esta guía aparecen como texto. Los valores son los mismos.

Celda inicial: la tabla de ventas

Datos de ventas de una semana en la cafetería. Esta celda debe ejecutarse primero, siempre. Si más adelante algo dice que df no existe, vuelve a ejecutarla.

```
import pandas as pd

ventas = {
    "producto": ["Jugo", "Sandwich", "Galleta", "Agua", "Empanada", "Café", "Barra
cereal", "Té"],
    "categoria": ["Bebida", "Comida", "Snack", "Bebida", "Comida", "Bebida", "Snack",
"Bebida"],
    "precio": [800, 1500, 600, 500, 1800, 1000, 700, 900],
    "unidades": [30, 18, 25, 40, 12, 15, 22, 10]
}
df = pd.DataFrame(ventas)
df["total"] = df["precio"] * df["unidades"]
df
```

```
       producto categoria  precio  unidades  total
0          Jugo    Bebida     800        30  24000
1      Sandwich    Comida    1500        18  27000
2       Galleta     Snack     600        25  15000
3          Agua    Bebida     500        40  20000
4      Empanada    Comida    1800        12  21600
5          Café    Bebida    1000        15  15000
6  Barra cereal     Snack     700        22  15400
7            Té    Bebida     900        10   9000
```

Cada fila es un producto. `total` es lo que se recaudó: precio por unidades.

Parte 1. Leer un mensaje de error

Un error no significa que lo hiciste mal: es una pista. Para leerlo, sigue tres pasos:

- **1.** Mira la **última línea** del mensaje. Dice el tipo de error y la causa.
- **2.** Busca la flecha que señala en qué línea de tu código ocurrió.
- **3.** Revisa lo más común: un nombre mal escrito (mayúsculas), un paréntesis que falta o una celda anterior sin ejecutar.

Prueba tú. Escribe cada línea en una celda distinta. Las cuatro darán error. Anota la última línea de cada error y cómo lo arreglarías.

Código	Última línea del error	Cómo se arregla
A. `df["Precio"]`		
B. `print(dff)`		
C. `df[df["precio"] > 600 & df["unidades"] > 20]`		
D. `pd.read_csv("ventas_cafeteria.csv")`		

Parte 2. El índice después de filtrar y las copias

Índice saltado. Al filtrar, cada fila conserva su número original. No es un error. Para volver a numerar desde 0 se usa `reset_index(drop=True)`.

```
caros = df[df["precio"] >= 800]
print(caros)
caros = caros.reset_index(drop=True)
print(caros)
```

```
   producto categoria  precio  unidades  total
0      Jugo    Bebida     800        30  24000
1  Sandwich    Comida    1500        18  27000
4  Empanada    Comida    1800        12  21600
5      Café    Bebida    1000        15  15000
7        Té    Bebida     900        10   9000
   producto categoria  precio  unidades  total
0      Jugo    Bebida     800        30  24000
1  Sandwich    Comida    1500        18  27000
2  Empanada    Comida    1800        12  21600
3      Café    Bebida    1000        15  15000
4        Té    Bebida     900        10   9000
```

Copias. Si modificas una tabla, cambias la original. Con `df.copy()` trabajas en una copia y la original queda igual.

```
copia = df.copy()
copia["precio"] = copia["precio"] * 2
print(df["precio"].tolist())
print(copia["precio"].tolist())
```

```
[800, 1500, 600, 500, 1800, 1000, 700, 900]
[1600, 3000, 1200, 1000, 3600, 2000, 1400, 1800]
```

Prueba tú. a) Filtra los productos con `unidades >= 20` y reinicia el índice. b) Crea una copia con `unidades` multiplicadas por 2 y comprueba que `df` no cambió. Anota cuántas filas tiene a) y la lista de unidades de `df` en b).

Tu respuesta:

Parte 3. Modificar una tabla

Cambiar un valor se hace con `loc[fila, "columna"]`. Para quitar una columna se usa `drop(columns=[...])`, que entrega una tabla nueva y deja la original intacta.

```
copia = df.copy()
copia.loc[0, "precio"] = 850
copia["total"] = copia["precio"] * copia["unidades"]
print(copia.loc[0])

sin_total = copia.drop(columns=["total"])
print(sin_total.columns.tolist())
print(copia.columns.tolist())
```

```
producto       Jugo
categoria    Bebida
precio          850
unidades         30
total         25500
Name: 0, dtype: object
['producto', 'categoria', 'precio', 'unidades']
['producto', 'categoria', 'precio', 'unidades', 'total']
```

Prueba tú. Haz una copia de `df` y cambia el precio del Agua (fila 3) a 550. Muestra el precio nuevo en la copia y el precio de `df`. Anota los dos valores.

Tu respuesta:

Parte 4. Ordenar y contar

```
print(df.sort_values("total", ascending=False).head(3))
print(df["categoria"].unique().tolist())
print(df["categoria"].nunique())
print(df["categoria"].value_counts())
```

```
   producto categoria  precio  unidades  total
1  Sandwich    Comida    1500        18  27000
0      Jugo    Bebida     800        30  24000
4  Empanada    Comida    1800        12  21600
['Bebida', 'Comida', 'Snack']
3
categoria
Bebida    4
Comida    2
Snack     2
Name: count, dtype: int64
```

- `sort_values("col", ascending=False)` ordena de mayor a menor.
- `unique()` lista los valores distintos y `nunique()` dice cuántos son.
- `value_counts()` cuenta cuántas veces aparece cada valor.

Prueba tú. ¿Cuántos productos hay de cada categoría? ¿Cuáles son los 3 productos con más unidades vendidas (muestra solo producto y unidades)?

Tu respuesta:

Parte 5. Estadísticas de una columna

Sobre una columna numérica puedes calcular `mean()` (promedio), `max()`, `min()` y `sum()`. Con `idxmax()` obtienes la fila donde está el máximo, y con `loc` puedes averiguar a qué producto corresponde.

```
print(df["precio"].mean())
print(df["precio"].max())
print(df["precio"].min())
print(df["unidades"].sum())
print(df["total"].sum())
print(df["unidades"].idxmax())
print(df.loc[df["unidades"].idxmax(), "producto"])
```

```
975.0
1800
500
172
147000
3
Agua
```

Prueba tú. Calcula el precio promedio, indica qué producto vendió más unidades y cuánto fue el total más alto.

Tu respuesta:

Parte 6. Agrupar con groupby

Sirve para comparar grupos. Se lee así: "agrupa por `categoria` y, para cada grupo, calcula esto con tal columna".

```
print(df.groupby("categoria")["unidades"].sum())
print(df.groupby("categoria")["precio"].mean())
print(df.groupby("categoria").size())
resumen = df.groupby("categoria")["total"].sum().reset_index()
print(resumen)
```

```
categoria
Bebida    95
Comida    30
Snack     47
Name: unidades, dtype: int64
categoria
Bebida     800.0
Comida    1650.0
Snack      650.0
Name: precio, dtype: float64
categoria
Bebida    4
Comida    2
Snack     2
dtype: int64
  categoria  total
0    Bebida  68000
1    Comida  48600
2     Snack  30400
```

`size()` cuenta filas por grupo. Con `reset_index()` el resultado vuelve a ser una tabla normal, que puedes mostrar o guardar.

Prueba tú. Calcula el precio promedio por categoría y el total de unidades por categoría. ¿Qué categoría vende más unidades?

Tu respuesta:

Para tu portafolio

☐ Guarda tu cuaderno de Colab con el nombre Apellido_dataframes.

☐ Toma una captura de pantalla de tu mejor resultado y escribe una frase que explique qué muestra.

☐ En tu bitácora anota: un error que tuviste, cómo lo leíste y cómo lo solucionaste.

Respuestas para comprobar

Úsalas después de intentarlo tú

Parte 1: errores

Código	Última línea del error	Cómo se arregla
A	KeyError: 'Precio'	La columna se llama `precio`, con minúscula: `df["precio"]`.
B	NameError: name 'dff' is not defined	Escribe bien el nombre: `print(df)`.
C	ValueError: The truth value of a Series is ambiguous...	Cada condición va entre paréntesis: `df[(df["precio"] > 600) & (df["unidades"] > 20)]`.
D	FileNotFoundError: [Errno 2] No such file or directory: 'ventas_cafeteria.csv'	El archivo no existe en `/content`. Créalo con `df.to_csv(...)` o súbelo, y comprueba con `os.listdir()`.

Parte 2

```
       producto categoria  precio  unidades  total
0          Jugo    Bebida     800        30  24000
1       Galleta     Snack     600        25  15000
2          Agua    Bebida     500        40  20000
3  Barra cereal     Snack     700        22  15400
[30, 18, 25, 40, 12, 15, 22, 10]
```

La tabla filtrada tiene 4 filas (índices 0 a 3 tras el reinicio) y `df` mantiene sus unidades originales.

Parte 3

```
550
500
```

La copia cambia a 550 y la original sigue en 500.

Parte 4

```
categoria
Bebida    4
Comida    2
Snack     2
Name: count, dtype: int64
  producto  unidades
3     Agua        40
0     Jugo        30
2  Galleta        25
```

Parte 5

```
975.0
Agua
27000
```

Promedio 975.0; el producto con más unidades es Agua; el total más alto es 27000 (Sandwich).

Parte 6

```
categoria
Bebida     800.0
Comida    1650.0
Snack      650.0
Name: precio, dtype: float64
categoria
Bebida    95
Comida    30
Snack     47
Name: unidades, dtype: int64
```

Bebida es la categoría que más unidades vende (95).