COLEGIO ARRIARÁN BARROS

Pensamiento Computacional y Programación · 3° y 4° Medio

Actividad: conocer un dataset

Primer vistazo a una tabla de datos (se trabaja en Google Colab)

Nombre:	**Curso:**	**Fecha:**

Sobre los datos. El archivo `datos_habitos_estudiantes.csv` es una encuesta ficticia (datos inventados) sobre hábitos de estudiantes de 3° y 4° Medio. Cada fila es un estudiante. Las columnas son:

Columna	Significado
`id`	Número del estudiante en la encuesta
`curso`	Curso (3°A, 3°B, 4°A, 4°B)
`edad`	Edad en años
`horas_sueno`	Horas que duerme por noche (promedio)
`horas_pantalla`	Horas diarias frente a pantallas (fuera de clases)
`horas_estudio`	Horas diarias que estudia en casa
`deporte`	¿Practica algún deporte? (Sí o No)
`transporte`	Cómo llega al colegio
`nota_promedio`	Promedio de notas del semestre (escala 1,0 a 7,0)

Antes de empezar

- Abre un cuaderno nuevo en Colab y **arrastra el archivo CSV** al panel Archivos (carpeta `content`), o súbelo con el ícono de subir.
- Cada ejercicio va en su propia celda. Escribe el código, ejecútalo y anota en la tabla lo que apareció.
- Si el tipo de una columna de texto aparece como `str` u `object`, es normal: depende de la versión de pandas.

Ejercicio 1 — Cargar el archivo y mirar el inicio — ~10 min

Antes de leer un archivo hay que comprobar que está en la carpeta de trabajo. Luego se lee con `read_csv` y se muestran las primeras 5 filas con `head()`.

```
import pandas as pd
import os

print(os.listdir())
df = pd.read_csv("datos_habitos_estudiantes.csv")
display(df.head())
```

Línea	Lo que mostró
`print(os.listdir())`	
`display(df.head())`	

Pregunta. Según `os.listdir()`, ¿el archivo está en la carpeta? ¿Qué pasaría si no lo estuviera?

Escribe tu respuesta aquí.

Ejercicio 2 — Tamaño, columnas y tipos

~10 min

`shape` entrega (filas, columnas), `columns` los nombres y `dtypes` el tipo de dato de cada columna.

```
print(df.shape)
print(df.columns.tolist())
print(df.dtypes)
```

Línea	Lo que mostró
`print(df.shape)`	
`print(df.columns.tolist())`	
`print(df.dtypes)`	

Pregunta. ¿Cuántos estudiantes (filas) y cuántas variables (columnas) tiene la tabla? ¿Cuáles columnas son numéricas y cuáles son texto?

Escribe tu respuesta aquí.

Ejercicio 3 — Columnas de categorías

~12 min

`value_counts()` cuenta cuántas veces aparece cada valor de una columna de categorías. `nunique()` dice cuántos valores distintos hay.

```
print(df["curso"].value_counts())
print(df["transporte"].value_counts())
print(df["deporte"].value_counts())
print(df["curso"].nunique())
```

Línea	Lo que mostró
`print(df["curso"].value_counts())`	
`print(df["transporte"].value_counts())`	
`print(df["deporte"].value_counts())`	

Línea	Lo que mostró
`print(df["curso"].nunique())`	

Pregunta. ¿Qué medio de transporte es el más usado? ¿Cuántos cursos distintos hay?

Escribe tu respuesta aquí.

Ejercicio 4 — Columnas numéricas

~12 min

Con dos corchetes eliges varias columnas numéricas a la vez, y `mean()`, `max()` y `min()` se calculan para cada una.

```
num = df[["horas_sueno", "horas_pantalla", "horas_estudio", "nota_promedio"]]
print(num.mean().round(2))
print(num.max())
print(num.min())
```

Línea	Lo que mostró
`print(num.mean().round(2))`	
`print(num.max())`	
`print(num.min())`	

Pregunta. ¿Cuál es el promedio de horas de sueño? ¿Y la nota promedio más alta y más baja del grupo?

Escribe tu respuesta aquí.

Ejercicio 5 — Primeras preguntas con los datos

~16 min

Ahora usa lo que sabes (filtros y `groupby`) para responder preguntas con estos datos.

```
print(len(df[df["horas_sueno"] < 7]))
print(df[df["nota_promedio"] >= 5.5][["curso", "nota_promedio"]])
print(df.groupby("deporte")["nota_promedio"].mean().round(2))
print(df.groupby("curso")["horas_pantalla"].mean().round(2))
```

Línea	Lo que mostró
`print(len(df[df["horas_sueno"] < 7]))`	

Línea	Lo que mostró
`print(df[df["nota_promedio"] >= 5.5][["curso", "nota_promedio"]])`	
`print(df.groupby("deporte")["nota_promedio"].mean().round(2))`	
`print(df.groupby("curso")["horas_pantalla"].mean().round(2))`	

Pregunta. Con los resultados de los `groupby`, ¿quiénes tienen mayor nota promedio: quienes hacen deporte o quienes no? ¿Qué curso pasa más horas frente a pantallas?

Escribe tu respuesta aquí.

Mi pregunta para este dataset

Piensa en lo que descubriste y escribe una pregunta que te gustaría responder con estos datos. Debe poder contestarse con las columnas de la tabla.

Mi pregunta:

¿Qué columnas necesitarías para responderla?

Columnas:

¿Qué crees que vas a encontrar? (tu hipótesis)

Mi hipótesis:

Ficha del dataset

Completa con lo que averiguaste. Esta ficha te sirve más adelante para describir tu dataset en el análisis final.

Dato	Tu respuesta
Número de filas	
Número de columnas	
Columnas numéricas	
Columnas de categorías	

Dato	Tu respuesta
Categoría más frecuente de `transporte`	
Promedio de `horas_sueno`	

Para quien termine antes

- Ejecuta `df.describe()` y `df.info()`. ¿Qué información entregan que no sacaste antes?
- Calcula el promedio de `nota_promedio` para cada medio de transporte con `groupby`.
- Filtra a los estudiantes que duermen menos de 6 horas y revisa qué notas tienen.

Para tu portafolio

☐ Guarda tu cuaderno como Apellido_dataset.
☐ Captura de pantalla de un resultado y una frase que explique qué muestra.
☐ Bitácora: una dificultad de hoy y cómo la resolviste.