COLEGIO ARRIARÁN BARROS

Pensamiento Computacional y Programación · 3° y 4° Medio

Actividad: limpiar un dataset

Revisar y corregir datos con problemas (se trabaja en Google Colab)

Nombre:	**Curso:**	**Fecha:**

Situación. Es la misma encuesta de hábitos de estudiantes, pero esta versión viene con problemas: la planilla se llenó a mano y hay datos faltantes, una fila repetida y valores mal escritos. Antes de analizar, hay que revisar y limpiar. El archivo es `datos_habitos_estudiantes_sucio.csv`.

Qué significa limpiar

- Limpiar es **tomar decisiones y justificarlas**, no borrar todo lo que parece raro. Siempre hay que preguntarse: ¿qué pasa con mi análisis si dejo este dato?, ¿y si lo cambio?, ¿y si lo elimino?
- Una buena limpieza se puede explicar en una frase: "eliminé estas filas porque...".

Antes de empezar

- Sube `datos_habitos_estudiantes_sucio.csv` al panel Archivos de Colab (carpeta `content`).
- Cada ejercicio va en su celda. Escribe el código, ejecútalo y anota lo que apareció.
- Si ves `str` u `object` como tipo, o `pandas.DataFrame` o `pandas.core.frame.DataFrame` en el resultado de `info()`, es normal: depende de la versión de pandas.

Ejercicio 1 — Cargar y hacer un primer chequeo — ~12 min

`info()` muestra, para cada columna, cuántos valores no nulos tiene y de qué tipo es. `describe()` resume las columnas numéricas: si el mínimo o el máximo se ve raro, hay que revisar.

```
import pandas as pd

df = pd.read_csv("datos_habitos_estudiantes_sucio.csv")
print(df.shape)
df.info()
print(df[["horas_sueno", "horas_estudio", "nota_promedio"]].describe().round(2))
```

Línea	Lo que mostró
`print(df.shape)`	
`df.info()`	
`print(df[["horas_sueno", "horas_estudio", "nota_promedio"]].describe().round(2))`	

Pregunta. ¿Cuántas filas y columnas tiene? ¿Qué columnas tienen menos valores no nulos que el total de filas? ¿Qué te llama la atención en el valor máximo de `nota_promedio` y de `horas_estudio`?

Escribe tu respuesta aquí.

Ejercicio 2 — Encontrar valores faltantes ~12 min

`isna()` marca con True los valores faltantes (aparecen como NaN). Con `sum()` se cuentan por columna.

```
print(df.isna().sum())
print(df.isna().sum().sum())
print(df[df["horas_sueno"].isna()][["id", "curso", "horas_sueno"]])
print(df[df["nota_promedio"].isna()][["id", "curso", "nota_promedio"]])
```

Línea	Lo que mostró
`print(df.isna().sum())`	
`print(df.isna().sum().sum())`	
`print(df[df["horas_sueno"].isna()][["id", "curso", "horas_sueno"]])`	
`print(df[df["nota_promedio"].isna()][["id", "curso", "nota_promedio"]])`	

Pregunta. ¿Cuántos valores faltantes hay en total y en qué columnas?

Escribe tu respuesta aquí.

Ejercicio 3 — Encontrar y quitar duplicados ~10 min

Una fila duplicada es idéntica a otra. `duplicated()` la detecta y `drop_duplicates()` la elimina, dejando la primera.

```
print(df.duplicated().sum())
print(df[df.duplicated(keep=False)][["id", "curso", "deporte", "transporte",
"nota_promedio"]])
df = df.drop_duplicates()
print(df.shape)
```

Línea	Lo que mostró
`print(df.duplicated().sum())`	
`print(df[df.duplicated(keep=False)][["id", "curso", "deporte", "transporte", "nota_promedio"]])`	
`print(df.shape)`	

Pregunta. ¿Cuántas filas duplicadas había? ¿Cómo sabes que es el mismo estudiante? ¿Cuántas filas quedan?

Escribe tu respuesta aquí.

Ejercicio 4 — Detectar valores raros

~12 min

Un valor raro es posible en una columna, pero imposible en la realidad (una nota de 51 o 19 horas de estudio al día). Se encuentra con `max()` y con filtros.

```
print(df["nota_promedio"].max())
print(df[df["nota_promedio"] > 7][["id", "curso", "nota_promedio"]])
print(df["horas_estudio"].max())
print(df[df["horas_estudio"] > 8][["id", "curso", "horas_estudio"]])
```

Línea	Lo que mostró
`print(df["nota_promedio"].max())`	
`print(df[df["nota_promedio"] > 7][["id", "curso", "nota_promedio"]])`	
`print(df["horas_estudio"].max())`	
`print(df[df["horas_estudio"] > 8][["id", "curso", "horas_estudio"]])`	

Pregunta. ¿Por qué 51 de nota y 19 horas de estudio no pueden ser reales? ¿Qué valor crees que se quiso escribir en cada caso?

Escribe tu respuesta aquí.

Ejercicio 5 — Decidir y limpiar

~16 min

Ahora aplica decisiones. Trabaja sobre una copia (`df.copy()`), para no perder la tabla anterior. Lee los comentarios del código: dicen qué se hace y por qué.

```
limpio = df.copy()

# valores raros: se escribieron multiplicados por 10
limpio.loc[limpio["nota_promedio"] > 7, "nota_promedio"] =
limpio.loc[limpio["nota_promedio"] > 7, "nota_promedio"] / 10
limpio.loc[limpio["horas_estudio"] > 8, "horas_estudio"] =
limpio.loc[limpio["horas_estudio"] > 8, "horas_estudio"] / 10

# faltantes: horas de sueño se rellena con la mediana, transporte con "Sin dato"
limpio["horas_sueno"] = limpio["horas_sueno"].fillna(limpio["horas_sueno"].median())
limpio["transporte"] = limpio["transporte"].fillna("Sin dato")

# faltantes en la nota: se eliminan esas filas
limpio = limpio.dropna(subset=["nota_promedio"])

print(limpio.shape)
print(limpio.isna().sum().sum())
print(limpio[["horas_sueno", "horas_estudio", "nota_promedio"]].describe().round(2))
```

Línea	Lo que mostró
`print(limpio.shape)`	
`print(limpio.isna().sum().sum())`	

Línea	Lo que mostró
`print(limpio[["horas_sueno", "horas_estudio", "nota_promedio"]].describe().round(2))`	

Pregunta. ¿Cuántas filas quedaron? ¿Quedan valores faltantes? ¿Cuál es ahora el máximo de `nota_promedio`?

Escribe tu respuesta aquí.

Ejercicio 6 — Desafío: categorías escritas distinto ~8 min

Una misma categoría escrita de dos formas se cuenta como dos categorías distintas.

```
print(limpio["deporte"].value_counts())
limpio["deporte"] = limpio["deporte"].replace("si", "Sí")
print(limpio["deporte"].value_counts())
```

Línea	Lo que mostró
`print(limpio["deporte"].value_counts())`	
`print(limpio["deporte"].value_counts())`	

Pregunta. ¿Cuántos estudiantes hacen deporte antes y después del reemplazo?

Escribe tu respuesta aquí.

Tabla de decisiones

Completa con lo que decidiste en el ejercicio 5 (o con lo que harías tú) y justifica cada decisión.

Problema	¿Cuántas filas?	Qué hice	Por qué
Faltantes en `horas_sueno`			
Faltantes en `nota_promedio`			
Faltante en `transporte`			
Fila duplicada			
Nota de 51			
19 horas de estudio			

Para pensar

En el ejercicio 1 la nota promedio del grupo (fila `mean` de `describe()`) salía muy alta. Después de limpiar, ¿cuánto vale? ¿Qué habría pasado si hubieras sacado conclusiones sin limpiar?

Tu respuesta:

Para tu portafolio

- ☐ Guarda tu cuaderno como Apellido_limpieza.
- ☐ Captura de pantalla de la tabla de decisiones completa o de la comparación antes/después.
- ☐ Bitácora: la decisión que más dudaste y cómo la resolviste.